

SERS 혼합물 정량 — 업데이트

2026-07-29 · Recovery 패널 개선 + physics-informed DL 정량 조사 (drawable SERS ink 프로젝트)

1. Recovery 패널 개선 (UNMIXR 앱)

- Validate → Recovery 개명, nav에서 Quantify(절대정량) 앞으로 이동 (조성 복원이 상위 단계).
- VIP-band NNLS: 각 물질의 cross-talk 최소 판별 밴드로만 조성을 분해하는 옵션 추가.
- 자기설명 export: Recovery-Real-Quantify 모든 export에 README(무엇을·어떻게·결과) 동봉. 드리프트 삼각형은 export 시 제목·범례·읽기가이드 주입, 앱에서는 깔끔.
- calibration CSV 오류 방지: 잘못된 파일에 명확한 에러 + ratio-only 폴백(안 죽음).

2. Physics-informed DL 혼합물 정량

목표: 모든 조성·농도를 실험으로 측정할 수 없으므로, pure 스펙트럼 + calibration + 소수 known-ratio 혼합물만으로 임의 혼합물의 조성·농도를 예측하는 범용 도구. 물리 시뮬레이터(경쟁 Langmuir)가 학습 공간을 생성하고, DL이 역산을 학습, 실제 혼합물이 sim-to-real 보정.

Track A(스펙트럼→μM 회귀) · Track B(surface→solution 잔차 보정) 구현 (dl_quantify.py). 평가는 leave-one-map-out CV, 지표 = ½·Σ|예측 - 실제| 조성오차.

주요 결과


체제	NNLS	선형 RF	PLS	full-spectrum DL
Binary LOO (28)	27.5%	21.3%	26.5%	21.9%
Binary→Ternary 일반화	45.2%	42.7%	26.6%	33.4%
전체 35 LOO (ternary 포함)	31.0%	23.9%	26.5%	20.5%

- 쉬운 binary는 선형 RF/PLS로 충분 — DL 동급. 하지만 full 스펙트럼 입력 + 어려운(ternary) 예제를 학습에 포함하면 DL이 전체 조성에서 1등(20.5%).
- 절대 μM: 단일물질 calibration이 혼합 경쟁을 못 잡아 THI에서 폭발 → 현재 신뢰 불가. 조성 비율이 신뢰 가능한 결과.

핵심: THI에 묻힌 성분 복원 (연구 목표)


THI는 표면을 항상 지배 → 고전 NNLS는 묻힌 co-성분을 0으로 소실(검출 44%). 실제 합성 비율로 학습한 모델은 이를 되살림. 묻힌 성분 정보는 3개 B값이 아니라 full 스펙트럼 모양에 있음 — 그래서 full-spectrum 방법만 성공.

Composition classification on the ternary simplex (leave-one-out, 35 real mixtures)



Ternary simplex 분류: 점 색=예측 정확도(초록=정확), 꼭짓점=recovery±SE. NNLS는 THI 287%/DQ 48%로 붕괴, DL은 셋 다 ~100%로 균형 복원.

Seeing through THI's dominance: recovering the buried co-component classical NNLS loses it (→0); models trained on known ratios recover it



THI 및 묻힌 성분(빨간선=실제) 복원: NNLS는 0으로 소실, 학습 모델(PLS/DL)은 되살림.

3. 빨간(hard) 케이스 개선 벤치마크

잔여 오류 진단: 극단비율에서 DQ↔TBZ 혼동 + THI 잔여 묻힘 (9/35, median은 12%).

방법	전체 조성오차	red>0.35	묻힘 검출
단일 DL	19.2%	7/35	82%
(1) 앙상블 ×5 (bagging)	20.3%	7/35	88%
(2) PLS+앙상블 하이브리드	22.0%	6/35	100%

→ 앙상블-하이브리드는 marginal (검출 ↑, 정확도 소폭 ↓). 빨간 점은 분산이 아니라 체계적 hard case라 앙상블로 안 사라짐. 진짜 해법 = 데이터(극단비율·다양 조성) + 불확실성 플래깅. 하이브리드는 '성분 절대 놓치면 안 될 때'에 유효.

4. 결론 & 다음 단계

- 방법론적 결론: full-spectrum + 어려운 경쟁 예제 학습이면 DL이 고전기법을 넘음. 제약은 모델·픽셀 수가 아니라 서로 다른 조성의 수.
- 범용성: 워크플로(pure+calib+소수 mixture→학습→예측)는 시스템 무관하게 재사용 가능. 학습된 모델은 시스템별(재보정 필요). SERS 재현성이 전이의 관건 — drawable ink가 그 기반을 제공.
- 다음: (1) 독립 배치 blind 검증(내부 LOO를 넘어 real-sample 주장), (2) 농도축·조성 다양성 확대(DL 우위 확대), (3) 불확실성 플래깅.

코드: dl_quantify.py · 상세: docs/dl_quantification_findings.md · 예측표: docs/mixture_predictions.csv